



What Is

HUNSPELL?

Hunspell Framework

Hunspell is a spell checker and morphological analyzer designed for languages with rich morphology and complex word compounding or character encoding and can use UTF-8 encoded dictionaries.

- Used by many popular applications.
 - Open Office
 - Mozilla products - ThunderBird/ FireFox /SeaMonkey
 - Opera 10
 - Google Chrome
 - Apple's Snow Leopard

Hunspell in Brief

Requires two files to define the language that it is spell checking.

- Dic file - a dictionary containing words for the language
- Aff file - an “affix” file that defines the meaning of special flags in the dictionary.

Hunspell in Brief Cont...

More on Affix files.

- SET - setting the character encodings of affixes and dictionary files
- TRY - sets the change characters for suggestions
- REP - replacement table for multiple character corrections
- PFX - defines prefixes
- SFX - suffix classes

Hunspell in Brief Cont...

SET UTF-8

TRY esianrtolcdugmphbyfvkwzESIANRTOLCDUGMPHBYFVKWZ'

REP 2

REP f ph REP ph f

PFX A Y 1

PFX A 0 re .

SFX B Y 2

SFX B 0 ed [^y]

SFX B y ied y

Aff File

hello

try/B

work/AB

Dic File

"hello", "try", "tried", "work", "worked", "rework", "reworked".

Generate Crawl Analyze

Generate complete list of words by entering dic/aff pair.

Single Words

Base Word Generate

Compound Syntax

Files

Dic File Browse

Generate

අංක
අංකය
අංකයක්
අංකයෙන්
අංකයන්
අංක
අංකයන්ට
අංකල්
අංකනය
අංකෙට
අංකුර
අංකුර

Analyze Save to File

Generate Crawl Analyze

Process and analyze a given wordlist.

Analyze

Word File

/home/buddhika/sinhala_full_word_list.txt

Browse

Word	Frequency
අංශය	1
අංශවල	1
අංශයන්ගේ	1
අංශයන්ද	1
අංශයන්	2
අංගතවලට	1
අංගතයේදී	1
අංශයන්ද	1
අංශයට	1
අංගතය	1
අංශයන්ගෙන්	1
අංශොඩ	1
අංශයන්	1
අංශයකි	1
අංගතයකට	1

Move >>

<< Move

Del >>

<< Del

Load

Remove

Add

Frequency

All



Save

Word	Frequency
අංකුර	1
අංකෙට	1
අංකයන්	1
අංකයන්ට	1
අංකයෙන්	1
අංකතය	1
අංකොට	1
අංකයන්	1
අංකුසය	1
අංකුසයන්	1
අංකෙලිය	
අංග	
අංගොල	
අංගතයට	
අංගතයේ	

Copy

Add

Modify

Remove

Find

Filter

Row Count

Add to blocked list

Add to ignored list

Load

Add

Frequency

Save

General
Crawl
Parsing
Categories
Word Lists

Category
verbs
▼
Modify
Delete
Add New Category

Option	Strip	Append	Condition
SFX	ହେଉ	ଡି	ହେଉ
SFX	ହେଉ	ସ୍ତ୍ର	ହେଉ
SFX ▼	ହେଉ	ସ୍ତ୍ର	ହେଉ
PFX			
SFX			

Delete Row
Add New Row
Save Changes

2. Rule building for various categories to expand words

Save Settings

Cancel

Generate

Crawl

Analyze

Use this area to crawl a given source and extract words to generate a wordlist.

Crawl

URL

Start

Pause

සඳුදා
සඳුදා
කඩගමුව
මාපිටිය
පාලම
ප්‍රකාශ
අයිතියට
ලෝකයම
විශ්ව
ගම්මානයක්
කරමට
කුඩා
වික
සමයේ
සංවර්ධනයේ
පසුබිම
නිසා
අප
රටේ
අසල්වැසි
ගම්මාන
පවා
පුරප්පේ
විම

Analyze

Save to File

3. Word harvesting

General Crawl Parsing Categories Word Lists

Crawl Settings

Domain

Max Depth

Max Pages

Max Words

Crawler Name

Add Words

Use this section to add new words to the dictionary.

Word to add

Suggest

Category

None



Generate

[Modify Categories](#)

Add New Word

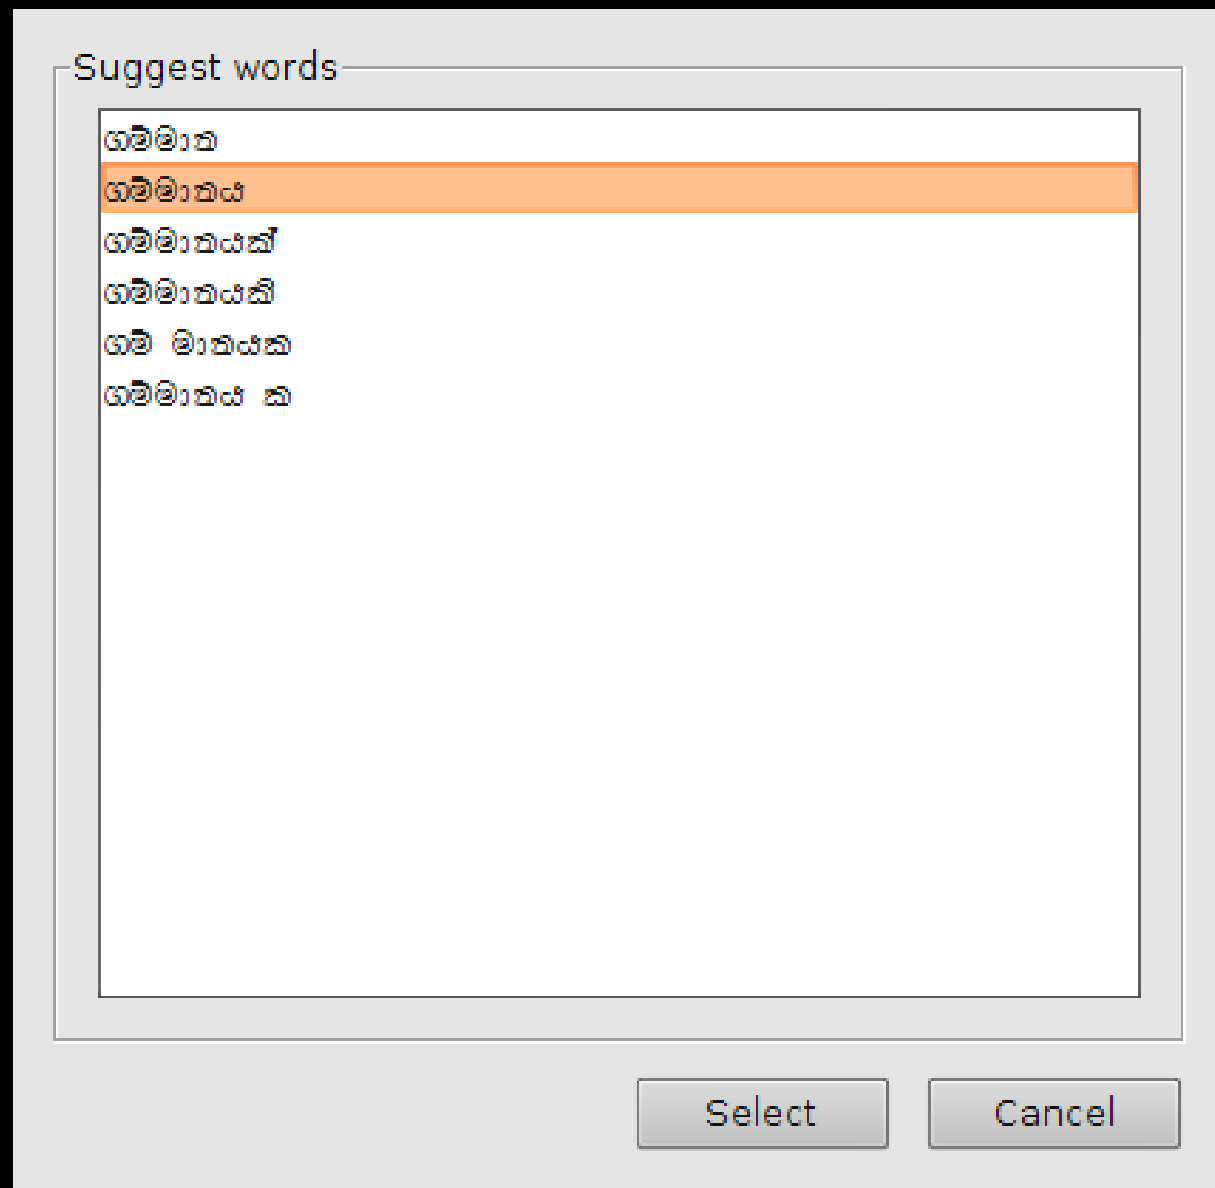
Modify Selected

Remove Selected

Add Directly

Add From Table

Cancel



Add Words

Use this section to add new words to the dictionary.

Word to add

അമൃതം

Suggest

Category

noun



Generate

[Modify Categories](#)

None

verbs

noun

Add New Word

Modify Selected

Remove Selected

Add Directly

Add From Table

Cancel

Add Words

Use this section to add new words to the dictionary.

Word to add

Suggest

Category



Generate

[Modify Categories](#)

അമിതാഹു
അമിതാഹു
അമിതാഹു
അമിതാഹു

Add New Word

Modify Selected

Remove Selected

Add Directly

Add From Table

Cancel

Generate

Crawl

Analyze

Process and analyze a given wordlist.

Analyze

Word File

/home/buddhika/NetBeansProjects/SinhalaDictionaryTools/tmp/tmp2

Browse

Word	Frequency
වත	6
සමයේ	2
සංවර්ධනයේ	1
පසුබිම	1
තීසා	8
අප	4
රටේ	> 2
අසල්වැසි	< 3
ගම්මාන	= 3
පවා	= 3
දුරස්ථ	> 3
එම	> 3
යුගය	< 4
අවසන්ව	= 4
අරුමුණ	> 4

Load

Add

Frequency

All

Save

Word	Frequency
සඳිව	2
ජාල	2
තවගමුව	2
මාපිටිගම	2
පාලම	2
ජනතා	2
අසිතිසව	2
ලොකයම	1
විශ්ව	1
ගම්මානයක්	1
කරමට	1
කුඩා	1
වත	6
සමයේ	2
සංවර්ධනයේ	1

Move >>

<< Move

Del >>

<< Del

Load

Remove

Add

Frequency

All

Save

General Crawl Parsing Categories Word Lists

Manage Lists

Word List Blocked Word List ▼

Highlighted Colour 